

ĐẠI HỌC CÔNG NGHỆ
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



23020425 Phạm Hải Tiến
23020343 Đỗ Việt Dũng

**FINGPT: BỘ TIÊU CHÍ ĐÁNH GIÁ TÍNH CHỈNH
HƯỚNG DẪN CHO MÔ HÌNH NGÔN NGỮ LỚN
MÃ NGUỒN MỞ VỀ LĨNH VỰC TÀI CHÍNH**

BÁO CÁO ĐỀ TÀI KHOA HỌC

Lớp: AIT 3005 *1

Seminar khoa học

Tóm tắt nội dung

Trong lĩnh vực Xử lý ngôn ngữ tự nhiên (NLP) đang mở rộng nhanh chóng, tiềm năng của các mô hình dựa trên GPT cho lĩnh vực tài chính ngày càng rõ ràng. Tuy nhiên, việc tích hợp các mô hình này với các tập dữ liệu tài chính đặt ra những thách thức, đáng chú ý là trong việc xác định tính phù hợp và liên quan của chúng.

Báo cáo này giới thiệu một phương pháp tiếp cận đặc biệt được neo giữ trong mô hình Tinh chỉnh hướng dẫn cho các mô hình ngôn ngữ lớn nguồn mở, được tinh chỉnh cụ thể cho các bối cảnh tài chính. Thông qua phương pháp này, chúng tôi tận dụng khả năng tương tác của các mô hình nguồn mở, đảm bảo tích hợp liền mạch và minh bạch. Chúng tôi bắt đầu bằng cách giải thích mô hình Tinh chỉnh hướng dẫn, nhấn mạnh hiệu quả của nó đối với việc tích hợp ngay lập tức. Bài báo trình bày một chương trình đánh giá chuẩn được thiết kế cho đào tạo và kiểm tra toàn diện, sử dụng tiến trình tiết kiệm chi phí.

Đầu tiên, chúng tôi đánh giá các năng lực cơ bản và các nhiệm vụ cơ bản, chẳng hạn như Nhận dạng thực thể có tên (NER) và phân tích tình cảm để nâng cao tính chuyên môn hóa. Tiếp theo, chúng tôi đi sâu vào một mô hình toàn diện, thực hiện các hoạt động đa nhiệm vụ bằng cách kết hợp tất cả các tinh chỉnh hướng dẫn để kiểm tra tính linh hoạt. Cuối cùng, chúng tôi khám phá khả năng zero-shot bằng cách phân bổ các nhiệm vụ chưa từng thấy và kết hợp các tập dữ liệu mới để hiểu khả năng thích ứng trong các địa hình chưa được khám phá. Một mô hình như vậy củng cố các nguyên tắc về tính cởi mở và khả năng tái tạo, đặt nền tảng vững chắc cho các cuộc điều tra trong tương lai về các mô hình ngôn ngữ lớn tài chính nguồn mở (FinLLM). Code được mã nguồn mở tại: <https://github.com/AI4Finance-Foundation/FinGPT>.

Mục lục

1	Giới thiệu	5
1.1	Bối cảnh thế giới	5
1.2	Lí do nghiên cứu	5
2	Nghiên cứu liên quan	5
2.1	Tổng quan về LLMs	5
2.2	LLMs về tài chính	6
3	Mô hình được đề xuất	7
3.1	Tính chỉnh hướng dẫn theo đơn tác vụ	7
3.2	Tính chỉnh hướng dẫn theo đa tác vụ	7
3.3	Tính chỉnh hướng dẫn hướng đến khả năng Zero-shot	7
4	Chi tiết quá trình triển khai	7
4.1	Chuẩn bị dữ liệu	8
4.2	Xây dựng hướng dẫn	8
4.3	Chi tiết huấn luyện	9
5	Kết quả thí nghiệm	9
5.1	Tính chỉnh hướng dẫn đơn tác vụ	9
5.2	Tính chỉnh đa tác vụ	10
5.3	Tính chỉnh cho khả năng Zero-shot	11
6	Kết luận và định hướng tương lai	11
7	Thử nghiệm	12
7.1	Thử nghiệm InstructionTuning	12
7.1.1	Mục tiêu	12
7.1.2	Quy trình thực hiện	12
7.1.3	Kết quả	12
7.2	Thử nghiệm so sánh 2 mô hình	13
7.2.1	Mục tiêu	13
7.2.2	Quy trình thực hiện	13
7.2.3	Kết quả	13

Danh sách từ viết tắt

NLP Xử lý ngôn ngữ tự nhiên (Natural Language Processing)

LLM Mô hình ngôn ngữ lớn (Large Language Model)

GPT Generative Pre-trained Transformer

FinLLM Mô hình ngôn ngữ tài chính

SA Phân tích cảm xúc (Sentiment Analysis)

HC Phân loại tiêu đề (Headline Classification)

NER Nhận diện thực thể có tên (Named Entity Recognition)

RE Trích xuất quan hệ tài chính (Financial Relation Extraction)

CLS Chuyển định dạng thành bài toán phân loại

1 Giới thiệu

1.1 Bối cảnh thế giới

Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP) đang nổi lên như một ngọn hải đăng cho ngành tài chính [32, 25, 15], mang đến những cơ hội đột phá và khả năng chuyển đổi vượt bậc. Các mô hình ngôn ngữ lớn (Large Language Models - LLMs) [27, 8], dựa trên nền tảng GPT, đang trở thành trung tâm thu hút sự chú ý nhờ vào khả năng nâng cao việc diễn giải và khai thác dữ liệu tài chính. Kỹ thuật tinh chỉnh theo hướng dẫn (Instruction Tuning) [29, 20] giúp tinh chỉnh các LLM đã được huấn luyện sẵn cho những tác vụ cụ thể một cách hiệu quả, tiết kiệm đáng kể thời gian và tài nguyên tính toán so với việc huấn luyện từ đầu.

Cách tiếp cận tiết kiệm chi phí này tận dụng các mô hình mã nguồn mở thông qua quy trình Instruction Tuning, đạt được—thậm chí vượt qua—hiệu năng của các mô hình mã nguồn đóng với mức đầu tư tài nguyên tối thiểu. Tuy vậy, vẫn còn thách thức trong việc tích hợp các mô hình này một cách hiệu quả, duy trì tính minh bạch và đảm bảo khả năng thích nghi linh hoạt với các nhiệm vụ tài chính đa dạng.

1.2 Lí do nghiên cứu

Các phương pháp hiện có, dù mang tính cách mạng theo cách riêng của chúng, vẫn còn thiếu sót ở một số khía cạnh quan trọng. Một số mô hình gặp khó khăn khi tích hợp dễ dàng với các tập dữ liệu tài chính đa dạng [16, 17]. Một số khác, tuy hoạt động tốt trong các bối cảnh tổng quát, lại dễ gặp vấn đề khi xử lý các thuật ngữ và tình huống chuyên biệt trong lĩnh vực tài chính [2, 33]. Do đó, có một nhu cầu rõ ràng đối với một mô hình toàn diện hơn, minh bạch hơn và có khả năng thích ứng tốt hơn với đặc thù ngành tài chính.

Trong báo cáo này, chúng tôi đề xuất một sơ đồ mới áp dụng mô hình Instruction Tuning để mở rộng khả năng của các LLM trong lĩnh vực tài chính. Sơ đồ này nổi bật nhờ nhấn mạnh vào tính minh bạch, khả năng tái sử dụng và khả năng tích hợp mô hình theo kiểu "plug-and-play". Nghiên cứu của chúng tôi bao gồm việc trình bày khuôn khổ Instruction Tuning, đánh giá sâu về năng lực hiểu biết tài chính của các mô hình phổ biến hiện nay, cùng với thảo luận chi tiết về phương pháp luận đảm bảo quy trình huấn luyện nhất quán. Chúng tôi thu hẹp khoảng cách giữa các mô hình mã nguồn mở và dữ liệu tài chính, tạo nên sự hòa hợp giữa hai yếu tố này.


2 Nghiên cứu liên quan

Những năm gần đây đã chứng kiến sự gia tăng mạnh mẽ trong nghiên cứu tập trung vào việc kết hợp các tập dữ liệu tài chính với các mô hình dựa trên GPT như GPT-3 và GPT-4[8] nhằm nâng cao hiệu quả của các ứng dụng NLP. Nhìn chung, có hai phương pháp phổ biến hiện nay:

- Sử dụng kỹ thuật thiết kế lời nhắc (prompt engineering)[35, 30, 14] với các mô hình ngôn ngữ mã nguồn mở, giữ nguyên các tham số.
- Áp dụng các phương pháp tinh chỉnh có giám sát như Instruction Tuning [20] để xây dựng các mô hình ngôn ngữ lớn tập trung theo lĩnh vực, được thiết kế riêng cho các nhiệm vụ trong lĩnh vực tài chính.

2.1 Tổng quan về LLMs

- Llama2 [28] là một mô hình ngôn ngữ lớn mã nguồn mở do Meta phát triển, hỗ trợ 20 ngôn ngữ, được xây dựng dựa trên phiên bản tiền nhiệm Llama 1 [27].
- ChatGLM2 [33, 10] xuất hiện như một mô hình song ngữ dựa trên khung mô hình ngôn ngữ tổng quát (GLM)[11], hỗ trợ tiếng Anh và tiếng Trung.
- BLOOM [21] là mô hình ngôn ngữ đa ngữ mã nguồn mở lớn nhất thế giới, hỗ trợ 46 ngôn ngữ tự nhiên và 13 ngôn ngữ lập trình, đóng vai trò như một giải pháp đa ngữ toàn diện.



Hình 1: Tổng quan về mô hình huấn luyện theo hướng dẫn (Instruction Tuning) được đề xuất.

- Falcon[3] nổi tiếng với khả năng hỗ trợ đa ngôn ngữ, hiệu quả trong tính toán và chất lượng dữ liệu huấn luyện đến từ nhiều nguồn đa dạng.
- MPT [26] của MosaicML, được huấn luyện trước trên văn bản tiếng Anh và mã nguồn, sở hữu kiến trúc được tối ưu hóa, giúp nâng cao hiệu quả trong cả huấn luyện và suy luận.
- Qwen [6] từ Alibaba nổi bật nhờ khả năng xử lý mạnh mẽ cả tiếng Trung và tiếng Anh, trở thành một công cụ linh hoạt cho các ứng dụng đa ngôn ngữ.

2.2 LLMs về tài chính

- FinBERT[5] là một mô hình chuyên biệt cho phân tích cảm xúc trong lĩnh vực tài chính với quy mô dưới một tỷ tham số, được tinh chỉnh trên một tập dữ liệu tài chính phong phú để vượt trội trong các nhiệm vụ chuyên ngành.
- FLUE cung cấp một bộ chuẩn đánh giá dựa trên năm tập dữ liệu tài chính đa dạng, đóng vai trò như một công cụ đánh giá toàn diện cho khả năng hiểu ngôn ngữ trong tài chính. Mô hình dẫn xuất từ FLUE, FLANG-BERT, vượt trội hơn FinBERT trên các tập dữ liệu này nhờ các cải tiến chuyên biệt cho miền tài chính.
- BloombergGPT là một mô hình mã nguồn đóng dựa trên BLOOM, được huấn luyện mở rộng trên nhiều tập dữ liệu tài chính khác nhau, từ đó bao phủ một phổ rộng các lĩnh vực tài chính.
- FinGPT là một mô hình ngôn ngữ lớn mã nguồn mở, được tinh chỉnh từ một mô hình tổng quát bằng các phương pháp thích nghi hạng thấp, giúp tăng cường khả năng tiếp cận cho cộng đồng rộng lớn hơn.
- PIXIU hoạt động như một bộ chuẩn đánh giá và tập dữ liệu hướng dẫn. Nó chỉ tập trung vào tập dữ liệu chuẩn, chỉ đánh giá các mô hình dẫn xuất từ LLaMA mà không xem xét các mô hình mã nguồn mở khác.

Nghiên cứu hiện tại chủ yếu sử dụng các mô hình LLama làm nền tảng cho việc đánh giá các tác vụ tài chính, điều này hạn chế hiểu biết vì các mô hình mã nguồn mở khác có thể vượt trội trong những tác vụ cụ thể. Một đánh giá rộng hơn và bao quát hơn đối với nhiều mô hình mã nguồn mở có thể mang lại những hiểu biết về hiệu suất theo từng tác vụ và có thể khám phá ra các mô hình phù hợp tự nhiên với các ứng dụng tài chính cụ thể.

Nhận thức được những khoảng trống này, nghiên cứu của chúng tôi hướng tới việc trình bày một mô hình tích hợp và tinh vi hơn, nhằm kết hợp liền mạch các mô hình ngôn ngữ mã nguồn mở với dữ liệu tài chính phức tạp, từ đó đề xuất một giải pháp vững chắc cho các ứng dụng chuyên ngành.

3 Mô hình được đề xuất

Mô hình Instruction Tuning được đề xuất trong nghiên cứu này, được minh họa ở Hình 1, được thiết kế cẩn thận thành ba giai đoạn có mối liên hệ chặt chẽ với nhau, mỗi giai đoạn đóng vai trò quan trọng trong việc tích hợp liền mạch và phân tích toàn diện các bộ dữ liệu NLP trong lĩnh vực tài chính.

3.1 Tinh chỉnh hướng dẫn theo đơn tác vụ

Trong giai đoạn đầu tiên của mô hình, chúng tôi tiến hành phân tích kỹ lưỡng các năng lực nền tảng của các LLM đối với từng tác vụ NLP riêng biệt trong lĩnh vực tài chính. Mỗi tác vụ được xem xét một cách độc lập trong giai đoạn này, cho phép đánh giá chi tiết khả năng và hiệu suất vốn có của các LLM. Phương pháp tiếp cận tập trung này tạo ra những hiểu biết sâu sắc về điểm mạnh, hiệu quả và những khía cạnh cần cải thiện đối với từng LLM trong việc trích xuất, xử lý và phân tích dữ liệu tài chính từ nhiều nguồn khác nhau.

3.2 Tinh chỉnh hướng dẫn theo đa tác vụ

Tại giai đoạn thứ hai, chúng ta đánh giá khả năng thích ứng và linh hoạt của các LLM khi thực hiện đồng thời nhiều tác vụ NLP tài chính. Tại đây, các hướng dẫn huấn luyện được tích hợp lại, cho phép mô hình xử lý nhiều tác vụ cùng lúc và đánh giá khả năng xử lý đa nhiệm của chúng. Giai đoạn này được thiết kế để phản ánh môi trường tài chính phức tạp trong thực tế, nơi việc xử lý và phân tích đồng thời nhiều loại dữ liệu là điều tất yếu. Vì vậy, giai đoạn này đóng vai trò then chốt trong việc đánh giá tính thực tiễn và hiệu quả của việc triển khai LLM trong bối cảnh tài chính thực tế.

3.3 Tinh chỉnh hướng dẫn hướng đến khả năng Zero-shot

Giai đoạn cuối cùng này nhằm nâng cao khả năng zero-shot của các LLM. Ở đây, các LLM được thử thách với các tình huống và tác vụ chưa từng gặp trước đó nhằm đánh giá khả năng thích ứng, học hỏi linh hoạt và phản ứng trước các vấn đề mới trong lĩnh vực tài chính. Việc đưa vào các bộ dữ liệu mới và tác vụ chưa thấy tạo ra một môi trường kiểm thử khắt khe, từ đó đánh giá tính mạnh mẽ, linh hoạt và khả năng giải quyết vấn đề — những yếu tố thiết yếu trong bối cảnh tài chính luôn thay đổi.

4 Chi tiết quá trình triển khai

Trong phần này, chúng tôi trình bày chi tiết về các phương pháp được sử dụng trong các bước Chuẩn bị dữ liệu, Xây dựng hướng dẫn, và Huấn luyện. Các tài nguyên đầy đủ bao gồm tập dữ liệu, mã nguồn và các ví dụ minh họa có thể truy cập tại: https://github.com/AI4Finance-Foundation/FinGPT/tree/master/fingpt/FinGPT_Benchmark

4.1 Chuẩn bị dữ liệu

:Trong quá trình chuẩn bị dữ liệu, phương pháp của chúng tôi phù hợp với phương pháp mà BloombergGPT [31] sử dụng, trong đó một số bộ dữ liệu tài chính từ tiêu chuẩn FLUE [22] được áp dụng cho các tác vụ khác nhau.

Lựa chọn tập dữ liệu: Đối với tác vụ Phân tích cảm xúc (Sentiment Analysis - SA), chúng tôi sử dụng các bộ dữ liệu FPB [17] và FiQA-SA [16]. Đối với tác vụ Phân loại tiêu đề (Headline Classification - HC), bộ dữ liệu Headline [24] được sử dụng. Ngoài ra, bộ dữ liệu NER [4] được sử dụng cho tác vụ Nhận dạng thực thể có tên (Named Entity Recognition - NER).

Trích xuất quan hệ tài chính: Bên cạnh đó, chúng tôi còn triển khai vào lĩnh vực Trích xuất quan hệ tài chính (Financial Relation Extraction - RE). Để thực hiện điều này, chúng tôi sử dụng bộ dữ liệu FinRED [23], tạo nền tảng cho việc trích xuất và hiểu các quan hệ tài chính trong dữ liệu văn bản.

Lý do lựa chọn bộ dữ liệu: Các bộ dữ liệu được lựa chọn cẩn thận để bao quát một loạt các tác vụ NLP tài chính, mỗi bộ đóng góp một cách độc đáo vào sự hiểu biết và hiệu suất của mô hình đối với các tác vụ cụ thể. Chúng tôi cũng chú ý để đảm bảo các bộ dữ liệu này bổ sung cho nhau và việc tích hợp chúng sẽ giúp mô hình có cái nhìn toàn diện và chi tiết về khả năng của mình, đồng thời chỉ ra những điểm cần cải thiện và tinh chỉnh thêm.

4.2 Xây dựng hướng dẫn

Cấu trúc mẫu hướng dẫn:

Hướng dẫn: [câu lệnh] **Đầu vào:** [dữ liệu đầu vào] **Đầu ra:** [dữ liệu đầu ra]

Xây dựng hướng dẫn cho từng tác vụ cụ thể:

- **Phân tích cảm xúc:** Các hướng dẫn cho tác vụ SA được áp dụng trực tiếp từ FinGPT [34], nhằm tận dụng hiệu quả đã được thiết lập từ trước trong nghiên cứu của họ.
- **Phân loại tiêu đề:** Đối với tác vụ HC, chúng tôi sử dụng bộ hướng dẫn từ Bloomberg [31], tận dụng cách tiếp cận phù hợp với thực tiễn ngành tài chính mà họ đã phát triển.
- **Tác vụ Nhận dạng thực thể có tên và Trích xuất quan hệ:** Đối với hai tác vụ NER và RE, các hướng dẫn được xây dựng cẩn thận bởi nhóm nghiên cứu, nhằm đáp ứng những đặc thù và yêu cầu riêng biệt của từng tác vụ này.

Điều chỉnh cho Thí nghiệm Đa Tác vụ và Zero-Shot: Để hỗ trợ các thí nghiệm đa tác vụ và zero-shot, chúng tôi đã thực hiện điều chỉnh đối với các tác vụ NER và RE, chuyển đổi chúng thành các tác vụ phân loại, được gọi là NER(CLS) và RE(CLS). Việc định dạng lại này giúp các tác vụ tương đồng với SA và HC, không chỉ mở rộng tập nhiệm vụ mà còn tăng cường khả năng khái quát hóa của các LLM.

Task	Dataset	Total Samples
Sentiment Analysis (CLS)	FPB	3634
	FiQA-SA	938
	TFNS	9543
	NWGI	16184
Named Entity Recognition	NER	609
Headline Classification (CLS)	Headline	11412×9
Relation Extraction	FinRED	6768
Named Entity Recognition (CLS)	NER	1003
Relation Extraction (CLS)	FinRED	9657

Hình 2: Tổng quan về các tác vụ và bộ dữ liệu.

Điều chỉnh cấu trúc mẫu hướng dẫn cho Thí nghiệm Zero-shot: Một phần [Options] được thêm vào mỗi hướng dẫn, giúp đơn giản hóa cách diễn đạt và hạn chế các câu trả lời bất ngờ từ các LLM. Cụ thể mẫu hướng dẫn được điều chỉnh như sau:

Hướng dẫn: [câu lệnh] **Đầu vào:** [dữ liệu đầu vào] **Đầu ra:** [dữ liệu đầu ra] **Option:** [các lựa chọn]

Các ví dụ cụ thể minh họa cách xây dựng hướng dẫn được trình bày trong Hình 1, nhằm cung cấp cái nhìn trực quan về việc áp dụng thực tế bộ mẫu hướng dẫn trong khuôn khổ thí nghiệm.

4.3 Chi tiết huấn luyện

Trong nghiên cứu của chúng tôi, sáu mô hình ngôn ngữ lớn mã nguồn mở (LLM) — Llama2-7B [18], Falcon-7B [2], BLOOM-7.1B [7], MPT-7B [19], ChatGLM2-6B[1], và Qwen-7B[9] — được chọn làm đối tượng để áp dụng mô hình tinh chỉnh hướng dẫn của chúng tôi. Tất cả các mô hình đều có kích thước tương đương và được sử dụng dưới dạng gốc, không sử dụng các phiên bản đã được huấn luyện theo hướng dẫn hoặc phiên bản chat, ngoại trừ ChatGLM2 (vì phiên bản gốc chưa được phát hành).

Sử dụng LoRA : Vì quá trình tinh chỉnh các mô hình LLM này đòi hỏi tài nguyên tính toán lớn, chúng tôi sử dụng phương pháp LoRA [12] với rank = 8 và hệ số nhân (alpha) = 32.

Trong ba giai đoạn của tinh chỉnh hướng dẫn:

- **Đơn tác vụ:** số lượng epoch được thiết lập là 8 cho các nhiệm vụ SA, HC và RE nhờ vào kích thước mẫu lớn của chúng. Nhiệm vụ NER, với kích thước mẫu hạn chế, cần thiết lập epoch là 50.
- **Đa tác vụ:** các mô hình được tiếp xúc với bộ dữ liệu kết hợp của các nhiệm vụ SA, HC, NER, RE, NER(CLS), và RE(CLS) trong tổng cộng 4 epoch. Các nhiệm vụ có kích thước mẫu nhỏ hơn được oversample để duy trì sự cân bằng.
- **Zero-shot:** các mô hình được fine-tune trên một bộ dữ liệu hợp nhất gồm NER(CLS), RE(CLS) và HC trong một epoch, sau đó được đánh giá trên nhiệm vụ SA. Các điểm kiểm tra được lưu lại một cách có hệ thống sau mỗi 100 bước và được chọn dựa trên tổn thất đánh giá liên quan đến nhiệm vụ SA.

Các tham số mô hình: Các thí nghiệm sử dụng bốn GPU RTX 3090, với chiều dài token tối đa là 512 và kích thước batch mỗi thiết bị là 4, cộng với 8 bước tích lũy gradient. Chúng tôi sử dụng bộ tối ưu AdamW[14], với tốc độ học ban đầu là 1×10^{-4} , giảm dần tuyến tính về 0 sau một đợt warm-up 3% theo bước, sử dụng độ chính xác FP16 để tối ưu chi phí.

Phân tích chi phí huấn luyện: Với giá thuê GPU là $\$3.36 \approx 87\,000$ VND mỗi giờ, công việc chuyên biệt theo nhiệm vụ cho sáu mô hình cơ bản trên bốn nhiệm vụ mất 30 giờ. Các công việc đa nhiệm và zero-shot yêu cầu khoảng 60 giờ do có nhiều hướng dẫn hơn mỗi mô hình cơ bản, tổng cộng là 90 giờ. Do đó, tổng chi phí huấn luyện là $\$302.4 \approx 7\,800\,000$ VND.

5 Kết quả thí nghiệm

5.1 Tinh chỉnh hướng dẫn đơn tác vụ

Tổng quan kết quả: Hình 8 tóm tắt kết quả của quá trình tinh chỉnh hướng dẫn cho từng tác vụ cụ thể. Đối với SA, chúng tôi báo cáo hiệu suất trung bình của các mô hình trên tất cả các tập con của tác vụ này, được đo bằng điểm F1 trung bình. Các chỉ số chi tiết cho từng tập dữ liệu SA được trình bày trong Hình 4. Với NER, chúng tôi sử dụng điểm F1 ở cấp độ thực thể để đánh giá. Đối với HC và RE, chúng tôi lần lượt báo cáo điểm F1 tương ứng với mỗi tác vụ. Riêng với tác vụ RE, chúng tôi chỉ đánh giá điểm F1 dựa trên các quan hệ đã được nhận diện, và không xét đến các bộ ba (quan hệ, chủ thể, đối tượng) đầy đủ.

Nhận định về hiệu suất: Llama2 đạt hiệu suất tổng thể nổi bật, thể hiện qua việc xếp hạng trung bình ở vị trí thứ hai trên tất cả các tác vụ. Các mô hình Falcon và Qwen thể hiện sự linh hoạt, đạt được hiệu suất ổn định và đồng đều trên toàn bộ các tác vụ. Ngược lại, BLOOM tuy có hiệu suất rất tốt trong các tác vụ

Dataset	Llama2	Falcon	MPT	BLOOM	ChatGLM2	Qwen
SA	0.820 (2)	0.804 (4)	0.821 (1)	0.748 (6)	0.798 (5)	0.811 (3)
NER	0.673 (3)	0.619 (5)	0.615 (6)	0.729 (1)	0.645 (4)	0.679 (2)
HC	0.942 (1)	0.940 (3)	0.938 (4)	0.930 (6)	0.942 (1)	0.936 (5)
RE	0.395 (3)	0.428 (1)	0.309 (6)	0.425 (2)	0.340 (5)	0.371 (4)
Avg Ranking	2.0	3.25	4.25	3.75	3.75	3.5

Hình 3: Kết quả tinh chỉnh hướng dẫn cho đơn tác vụ

Phase	Dataset	Llama2	Falcon	MPT	BLOOM	ChatGLM2	Qwen
Task-Specific	FPB	0.863	0.846	0.872	0.810	0.850	0.854
	FiQA	0.871	0.840	0.863	0.771	0.864	0.867
	TFNS	0.896	0.893	0.907	0.840	0.859	0.883
	NWGI	0.649	0.636	0.640	0.573	0.619	0.638
	Avg	0.820	0.804	0.821	0.748	0.798	0.811
Multi-Task	FPB	0.861↓	0.845↓	0.870↓	0.766↓	0.836↓	0.873 ↑
	FiQA	0.825↓	0.881 ↑	0.863-	0.737↓	0.822↓	0.870↑
	TFNS	0.890↓	0.880↓	0.892 ↓	0.789↓	0.858↓	0.890↑
	NWGI	0.652↑	0.647↑	0.651↑	0.530↓	0.618↓	0.653 ↑
	Avg	0.807	0.813	0.819	0.701	0.784	0.822
Performance Gain		-1.3%	+0.7%	-0.2%	-4.7%	-1.4%	+1.1%

Hình 4: Kết quả tinh chỉnh hướng dẫn cho tác vụ SA

như NER và RE, nhưng lại thể hiện kém trong các tác vụ phân loại, cụ thể là SA và HC. MPT dù đạt điểm cao nhất trong tác vụ SA, nhưng lại không đạt kết quả tốt ở hai tác vụ NER và RE.

5.2 Tinh chỉnh đa tác vụ

Thiết lập đánh giá hiệu suất: Phần này trình bày quy trình đánh giá hiệu suất của các LLM sau khi được tinh chỉnh đa tác vụ. Đồng thời, phần này cũng cung cấp phân tích so sánh giữa các mô hình được tinh chỉnh theo hai phương pháp: đa tác vụ và đơn tác vụ. Hình 4 trình bày kết quả cho tác vụ SA và các tập con của nó, trong khi Hình 5 thể hiện kết quả cho các tác vụ NER, HC và RE.

Hiệu suất trong các tác vụ phân loại: Ở các tác vụ phân loại như SA và HC, phần lớn các mô hình đều ghi nhận sự suy giảm nhẹ về hiệu suất khi được huấn luyện đồng thời với các tác vụ không liên quan trong thiết lập đa tác vụ. Tuy nhiên, có một ngoại lệ nổi bật là Qwen, mô hình này liên tục cải thiện hiệu suất

Task	Phase	Llama2	Falcon	MPT	BLOOM	ChatGLM2	Qwen
NER	Task-Specific	0.637	0.619	0.615	0.729	0.645	0.679
	Multi-Task	0.678↑	0.600↓	0.682↑	0.709 ↓	0.629↓	0.666↓
	Performance Gain	+4.1%	-1.9%	+6.7%	-2.0%	-1.6%	-1.3%
HC	Task-Specific	0.942	0.940	0.938	0.930	0.942	0.936
	Multi-Task	0.938 ↓	0.932↓	0.928↓	0.898↓	0.932↓	0.922↓
	Performance Gain	-0.4%	-0.8%	-1.0%	-3.2%	-1.0%	-1.4%
RE	Task-Specific	0.395	0.428	0.309	0.425	0.340	0.371
	Multi-Task	0.674↑	0.576↑	0.667↑	0.697 ↑	0.557↑	0.640↑
	Performance Gain	+27.2%	+14.8%	+35.8%	+27.2%	+21.7%	26.9%

Hình 5: Kết quả tinh chỉnh hướng dẫn cho các tác vụ NER, HC và RE

Dataset	Llama2	Falcon	MPT	BLOOM	ChatGLM2	Qwen
FPB	0.621	0.791	0.599	0.576	0.803	0.576
FiQA	0.565	0.625	0.591	0.517	0.631	0.517

Hình 6: Kết quả Zero-shot trên 2 tập dữ liệu FPB và FiQA

trên tất cả các tập con của SA. Bên cạnh đó, Falcon cũng cho thấy sự cải thiện ở một số khía cạnh cụ thể trong các tác vụ phân loại. Ngược lại, BLOOM, vốn đã có hiệu suất không cao trong giai đoạn tinh chỉnh đơn tác vụ, lại bị suy giảm hiệu suất nghiêm trọng nhất trong các tác vụ phân loại sau khi áp dụng tinh chỉnh đa tác vụ. **Hiệu suất trong các tác vụ trích xuất thông tin:** Đối với RE, tất cả các mô hình đều cho thấy sự cải thiện đáng kể, có thể là do việc tích hợp RE(CLS) và các tác vụ NLP tài chính bổ sung, cho thấy khả năng chưa học đủ (under-fitting) trong giai đoạn tinh chỉnh đơn tác vụ. Trong khi Llama2 và MPT thể hiện sự tiến bộ trong NER, không phải tất cả các mô hình đều phản ánh sự cải thiện này. Đáng chú ý, hai mô hình này cũng cho thấy sự cải thiện rõ rệt nhất trong RE. Đặc biệt, BLOOM đã có những bước tiến đáng kể, vượt qua Falcon và khẳng định lại vị thế vượt trội của mình trong các tác vụ trích xuất thông tin.

5.3 Tinh chỉnh cho khả năng Zero-shot

Nội dung: Nghiên cứu này trình bày kết quả của chúng tôi trong việc đánh giá khả năng zero-shot của các LLM sau khi được huấn luyện. Ban đầu, chúng tôi đã cố gắng sử dụng các tác vụ NER và RE gốc cho mục đích huấn luyện. Tuy nhiên, những tác vụ này không kích hoạt đầy đủ khả năng zero-shot của các mô hình do thiếu sự đa dạng trong hướng dẫn. Hạn chế này dẫn đến các vấn đề như mô hình tạo ra thông tin sai lệch và phản hồi không nhất quán đối với các lựa chọn được cung cấp. Do đó, để thực hiện đánh giá này, các mô hình LLM được huấn luyện trên ba tác vụ phân loại riêng biệt: HC, NER(CLS) và RE(CLS). **Điều chỉnh tác vụ để giảm hiện tượng tạo thông tin sai lệch:** Để giải quyết vấn đề này, các tác vụ NER và RE được chuyển thành các tác vụ phân loại nhằm thu hẹp khoảng cách với tác vụ SA. Ngoài ra, các mẫu có nhãn "neutral" bị loại bỏ để giảm nhầm lẫn trong thiết lập zero-shot.

Hiệu suất so sánh: Hình 6 trình bày điểm F1 trung bình trên hai bộ dữ liệu FiQA và FPB. ChatGLM2 cho kết quả vượt trội trong các tác vụ zero-shot, có thể nhờ được tinh chỉnh hướng đến đối thoại. Falcon cũng đạt hiệu suất tốt. Llama2 và MPT kém hơn nhưng vẫn cho thấy tiềm năng ở một số trường hợp. Trong khi đó, BLOOM và Qwen gặp khó khăn, thường xuyên phân loại sai thành "positive". Kết quả kém của BLOOM là điều đã được dự đoán, nhưng hiệu suất thấp của Qwen gây bất ngờ.

6 Kết luận và định hướng tương lai

Tóm lại, nghiên cứu này đã trình bày một mô hình tinh chỉnh hướng dẫn bao gồm ba bước: tinh chỉnh theo đơn tác vụ, tinh chỉnh đa tác vụ, và tinh chỉnh để đạt được khả năng Zero-shot cho các LLM trong lĩnh vực tài chính. Nghiên cứu đã làm rõ và minh họa những năng lực đa dạng cũng như các hạn chế tiềm ẩn của các mô hình LLM khi được áp dụng vào nhiều tác vụ NLP đặc thù trong tài chính. Thông qua các thử nghiệm và phân tích kỹ lưỡng, nghiên cứu đã khám phá ra những đặc điểm hiệu suất riêng biệt và cung cấp những hiểu biết giá trị về cách sử dụng các mô hình này một cách hiệu quả và phù hợp cho các ứng dụng tài chính cụ thể.

Công việc trong tương lai sẽ tập trung vào việc tích hợp thêm các mô hình cơ sở mã nguồn mở, nghiên cứu các mô hình lớn hơn với kích thước tham số từ 13 đến 100 tỷ, và nâng cao các nỗ lực để tăng cường độ vững chắc và khả năng tổng quát của các LLM. Đồng thời cũng sẽ phát triển các chiến lược để giảm thiểu sự can thiệp giữa các nhiệm vụ và hiện tượng tạo thông tin sai lệch[13], đảm bảo các phản hồi của mô hình chính xác và đáng tin cậy trên các nhiệm vụ đa dạng.

7 Thử nghiệm

7.1 Thử nghiệm Instruction Tuning

7.1.1 Mục tiêu

Huấn luyện và đánh giá mô hình DistilBERT cho bài toán phân loại cảm xúc văn bản tài chính, sử dụng kỹ thuật Instruction Tuning kết hợp LoRA.

7.1.2 Quy trình thực hiện

- Chuẩn bị dữ liệu:

Sử dụng bộ dữ liệu Financial PhraseBank, chuyển đổi nhãn số thành nhãn text (negative, neutral, positive), thêm trường instruction và tạo context theo định dạng instruction tuning. Cụ thể, trường instruction được thiết lập như sau:

What is the sentiment of this news? Please choose an answer from negative/neutral/positive.

Sau đó, trường *context* được xây dựng bằng cách kết hợp instruction, input và định dạng answer:

Instruction: What is the sentiment of this news? Please choose an answer from negative/neutral/positive.

Input: <nội dung văn bản> Answer:

- Khởi tạo mô hình:

Sử dụng DistilBERT .

- Áp dụng LoRA:

Cấu hình LoRA với $r = 8$, $\alpha = 32$ và $\text{dropout} = 0.1$ như trong nghiên cứu.

- Huấn luyện:

Huấn luyện mô hình đã áp dụng LoRA trên tập train.

- Đánh giá sau khi tinh chỉnh:

Đánh giá mô hình bằng F1-score.

- Lưu kết quả:

Lưu mô hình và kết quả dự đoán vào file CSV.

7.1.3 Kết quả

- F1-score trước và sau khi tinh chỉnh cho thấy mức cải thiện rõ rệt nhờ LoRA.

```
=== So sánh kết quả ===
distilbert-base-uncased F1-Score (Pre-Tuning): 0.071
distilbert-base-uncased F1-Score (Post-Tuning): 0.866
Cải thiện: 0.795
```

Hình 7: Kết quả thử nghiệm tinh chỉnh DistilBERT

- Kết quả chi tiết được lưu vào file `fingpt_comparison_distilbert.csv`.

7.2 Thử nghiệm so sánh 2 mô hình

7.2.1 Mục tiêu

So sánh hiệu quả của hai mô hình ngôn ngữ (DistilBERT và MobileBERT) trên cùng bài toán phân loại cảm xúc văn bản tài chính, đều sử dụng kỹ thuật LoRA.

7.2.2 Quy trình thực hiện

- Chuẩn bị dữ liệu:
Sử dụng cùng bộ dữ liệu và quy trình tiền xử lý như InstructionTuningDemo.
- Khởi tạo hai mô hình:
 - DistilBERT (distilbert-base-uncased)
 - MobileBERT (google/mobilebert-uncased)
- Áp dụng LoRA:
Cấu hình LoRA với các tham số như đã đề cập.
- Huấn luyện:
Huấn luyện từng mô hình trên tập train sau khi áp dụng LoRA.
- Đánh giá:
Đánh giá từng mô hình trên tập kiểm tra, ghi nhận F1-score.
- Lưu kết quả:
Lưu mô hình và kết quả dự đoán vào file CSV.

7.2.3 Kết quả

- F1-score của DistilBERT tốt hơn hẳn MobileBERT, do có nhiều tham số, độ phức tạp lớn hơn, cho phép mô hình học nhiều đặc trưng từ dữ liệu.

```
=== So sánh kết quả ===  
DistilBERT: F1-Weighted = 0.865  
MobileBERT: F1-Weighted = 0.464  
Kết quả đã được lưu vào fingpt_comparison.csv
```

Hình 8: Kết quả so sánh thử nghiệm tinh chỉnh DistilBERT và MobileBERT

- Kết quả chi tiết được lưu vào file `fingpt_comparison.csv`.

Tài liệu

- [1] Knowledge Engineering Group (KEG) and Data Mining at Tsinghua University (THUDM). *Chatglm2-6b*. 2023. <https://huggingface.co/THUDM/chatglm2-6b>.
- [2] Technology Innovation Institute (TII). *Falcon-7b*. 2023. <https://huggingface.co/tiiuae/falcon-7b>.

- [3] Ebtesam Almazrouei, Hamza Alobeidli, Abdulaziz Alshamsi, Alessandro Cappelli, Ruxandra Cojocaru, Merouane Debbah, Etienne Goffinet, Daniel Heslow, Julien Launay, Quentin Malartic, Badreddine Noune, Baptiste Pannier **and** Guilherme Penedo. “Falcon-40B: an open large language model with state-of-the-art performance”. **in**(2023).
- [4] Julio Cesar Salinas Alvarado, Karin Verspoor **and** Timothy Baldwin. “Domain adaption of named entity recognition to support credit risk assessment”. **in***Proceedings of the Australasian Language Technology Association Workshop 2015*: Parramatta, Australia, 2015, **pages** 84–90.
- [5] Dogu Araci. “Finbert: Financial sentiment analysis with pre-trained language models”. **in***arXiv preprint arXiv:1908.10063*: (2019). <https://arxiv.org/abs/1908.10063>.
- [6] Jinze Bai, Shuai Bai, Shusheng Yang, Shijie Wang, Sinan Tan, Peng Wang, Junyang Lin, Chang Zhou **and** Jingren Zhou. “Qwen-vl: A frontier large vision-language model with versatile abilities”. **in***arXiv preprint arXiv:2308.12966*: (2023). <https://arxiv.org/abs/2308.12966>.
- [7] *BLOOM-7B1*. 2023. <https://huggingface.co/bigscience/bloomz-7b1>.
- [8] Tom Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared D Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell **and** et al. “Language models are few-shot learners”. **in***Advances in Neural Information Processing Systems*: 33 (2020), **pages** 1877–1901.
- [9] Alibaba Cloud. *Qwen-7b*. 2023. <https://huggingface.co/Qwen/Qwen-7B>.
- [10] Zhengxiao Du, Yujie Qian, Xiao Liu, Ming Ding, Jiezhong Qiu, Zhilin Yang **and** Jie Tang. “GLM: General language model pretraining with autoregressive blank infilling”. **in***Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*: 2022, **pages** 320–335.
- [11] Zhengxiao Du, Yujie Qian, Xiao Liu, Ming Ding, Jiezhong Qiu, Zhilin Yang **and** Jie Tang. “GLM: general language model pretraining with autoregressive blank infilling”. **in**(2022): **pages** 320–335.
- [12] Edward J Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, Lu Wang **and** Weizhu Chen. “LoRA: Low-rank adaptation of large language models”. **in***International Conference on Learning Representations*: 2021.
- [13] Ziwei Ji, Nayeon Lee, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Ye Jin Bang, Andrea Madotto **and** Pascale Fung. “Survey of hallucination in natural language generation”. **in***ACM Computing Surveys*: 55.12 (2023), **pages** 1–38.
- [14] Vivian Liu **and** Lydia B Chilton. “Design guidelines for prompt engineering text-to-image generative models”. **in***Proceedings of the 2022 CHI Conference on Human Factors in Computing Systems*: 2022, **pages** 1–23.
- [15] Xiao-Yang Liu, Ziyi Xia, Jingyang Rui, Jiechao Gao, Hongyang Yang, Ming Zhu, Christina Wang, Zhaoran Wang **and** Jian Guo. “FinRL-Meta: Market environments and benchmarks for data-driven financial reinforcement learning”. **in***Advances in Neural Information Processing Systems*: **volume** 35. 2022, **pages** 1835–1849.
- [16] Macedo Maia, Siegfried Handschuh, André Freitas, Brian Davis, Ross McDermott, Manel Zarrouk **and** Alexandra Balahur. “WWW’18 open challenge: Financial opinion mining and question answering”. **in***Companion Proceedings of the the Web Conference*: 2018, **pages** 1941–1942.
- [17] Pekka Malo, Ankur Sinha, Pekka Korhonen, Jyrki Wallenius **and** Pyry Takala. “Good debt or bad debt: Detecting semantic orientations in economic texts”. **in***Journal of the Association for Information Science and Technology*: 65.4 (2014), **pages** 782–796.
- [18] Meta. *Llama-2-7b*. 2023. <https://huggingface.co/meta-llama/Llama-2-7b>.
- [19] MosaicML. *Mpt-7b*. 2023. <https://huggingface.co/mosaicml/mpt-7b>.
- [20] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray **and** others. “Training language models to follow instructions with human feedback”. **in***Advances in Neural Information Processing Systems*: **volume** 35. 2022, **pages** 27730–27744.

- [21] Teven Le Scao, Angela Fan, Christopher Akiki, Ellie Pavlick, Suzana Ilic, Daniel Hesslow, Roman Castagné, Alexandra Sasha Luccioni, François Yvon, Matthias Gallé **and others**. “Bloom: A 176b-parameter open-access multilingual language model”. *in arXiv preprint arXiv:2211.05100*: (2022).
- [22] Raj Sanjay Shah, Kunal Chawla, Dheeraj Eidnani, Agam Shah, Wendi Du, Sudheer Chava, Natraj Raman, Charese Smiley, Jiaao Chen **and** Diyi Yang. “When flue meets flang: Benchmarks and large pre-trained language model for financial domain”. *in arXiv preprint arXiv:2211.00083*: (2022).
- [23] Soumya Sharma, Tapas Nayak, Arusarka Bose, Ajay Kumar Meena, Koustuv Dasgupta, Niloy Ganguly **and** Pawan Goyal. “Finred: A dataset for relation extraction in financial domain”. *in Companion Proceedings of the Web Conference 2022, WWW ’22*: New York, NY, USA: Association for Computing Machinery, 2022, **pages** 595–597.
- [24] Ankur Sinha **and** Tanmay Khandait. *Impact of news on the commodity market: Dataset and results*. 2020.
- [25] Yen-Jen Tai **and** Hung-Yu Kao. “Automatic domain-specific sentiment lexicon generation with label propagation”. *in Proceedings of International Conference on Information Integration and Web-based Applications & Services*: 2013, **pages** 53–62.
- [26] MosaicML NLP Team. *Introducing mpt-7b: A new standard for open-source, commercially usable llms*. Accessed: 2023-05-05. 2023.
- [27] Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar **and others**. “Llama: Open and efficient foundation language models”. *in arXiv preprint arXiv:2302.13971*: (2023).
- [28] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale **and others**. “Llama 2: Open foundation and fine-tuned chat models”. *in arXiv preprint arXiv:2307.09288*: (2023).
- [29] Jason Wei, Maarten Bosma, Vincent Y Zhao, Kelvin Guu, Adams Wei Yu, Brian Lester, Nan Du, Andrew M Dai **and** Quoc V Le. “Finetuned language models are zero-shot learners”. *in arXiv preprint arXiv:2109.01652*: (2021).
- [30] Jules White, Quchen Fu, Sam Hays, Michael Sandborn, Carlos Olea, Henry Gilbert, Ashraf Elnashar, Jesse Spencer-Smith **and** Douglas C Schmidt. “A prompt pattern catalog to enhance prompt engineering with chatgpt”. *in arXiv preprint arXiv:2302.11382*: (2023).
- [31] Shijie Wu, Ozan Irsoy, Steven Lu, Vadim Dabravolski, Mark Dredze, Sebastian Gehrmann, Prabhajan Kambadur, David Rosenberg **and** Gideon Mann. “BloombergGPT: A large language model for finance”. *in arXiv preprint arXiv:2303.17564*: (2023).
- [32] Frank Z Xing, Erik Cambria **and** Roy E Welsch. “Natural language based financial forecasting: A survey”. *in Artificial Intelligence Review*: 50.1 (2018), **pages** 49–73.
- [33] Aohan Zeng, Xiao Liu, Zhengxiao Du, Zihan Wang, Hanyu Lai, Ming Ding, Zhuoyi Yang, Yifan Xu, Wendi Zheng, Xiao Xia **and others**. “Glm-130b: An open bilingual pre-trained model”. *in arXiv preprint arXiv:2210.02414*: (2022).
- [34] Boyu Zhang, Hongyang Yang **and** Xiao-Yang Liu. “Instruct-fingpt: Financial sentiment analysis by instruction tuning of general-purpose large language models”. *in arXiv preprint arXiv:2306.12659*: (2023).
- [35] Yongchao Zhou, Andrei Ioan Muresanu, Ziwen Han, Keiran Paster, Silviu Pitis, Harris Chan **and** Jimmy Ba. “Large language models are human-level prompt engineers”. *in arXiv preprint arXiv:2211.01910*: (2022).